

PDF-Sketch: 基于笔画段距离场与离散扩散的 布局式草图生成方法

周金, 周一, 徐鹏飞, 黄惠

(深圳大学计算机与软件学院, 广东 深圳 518060)

摘 要: 草图在概念设计、数字艺术和人机交互等领域具有重要价值, 但现有基于深度学习的生成方法常依赖折线或贝塞尔曲线进行几何表征, 难以刻画复杂形态, 且逐点预测机制易产生累计误差, 导致结构偏移与细节缺失。为此, 将草图建模为由多个独立笔画段构成的布局结构, 提出一种结合离散扩散模型与笔画段距离场 (PDF) 的生成框架。首先通过自适应笔画分解与笔画自编码器获取笔画段的连续可微特征表示, 再利用编码词典机制将高频相似的笔画形态离散化为有限词项, 使扩散过程能逐步恢复出结构合理的笔画段集合, 实现对笔画段位置、尺寸和形态的联合建模。在 QuickDraw 数据集上的实验结果表明, 该方法在 FID, Precision 和 Recall 等指标上均优于对比方法 Sketch-rnn 与 SketchKnitter。在少笔画任务中, 模型更好地学习局部几何特征, 召回率提升显著; 在多笔画任务中, 则展现出更高的结构精度和整体保真度。定性结果显示, 生成草图在整体一致性、局部细节还原和空间布局协调性方面均明显优于现有方法。研究表明, 从布局生成角度出发并结合距离场与离散化机制, 能够有效缓解传统序列建模中的误差累积问题, 提升草图生成的结构完整性与多样性, 为进一步改进笔画段分割、细节恢复及段间连接一致性提供了新的方向。

关 键 词: 矢量草图; 布局生成; 笔画分解; 笔画表示与学习; 距离场; 扩散模型

中图分类号: TP 391.41; TP 18

DOI: 10.11996/JGj.2095-302X.2026020380

文献标识码: A

文 章 编 号: 2095-302X(2026)02-0380-10

PDF-Sketch: layout-based sketch generation via primitive distance fields and discrete diffusion

ZHOU Jin, ZHOU Yi, XU Pengfei, HUANG Hui

(College of Computer Science and Software Engineering, Shenzhen University, Shenzhen Guangdong 518060, China)

Abstract: Sketches play an important role in conceptual design, digital art, and human - computer interaction. However, existing deep learning-based sketch generation methods often rely on polylines or Bézier curves for geometric representation, which are limited in capturing complex shapes. Sequential point prediction also leads to cumulative errors, causing structural distortion and loss of details. To address these issues, sketch generation was formulated as a layout modeling problem, where a sketch was composed of multiple independent stroke primitives. A framework was proposed that integrated a discrete diffusion model with the Primitive Distance Field (PDF). The method first applied adaptive stroke decomposition and a stroke autoencoder to obtain continuous and differentiable features of stroke segments. A codebook mechanism was then employed to discretize frequently recurring stroke patterns into a finite set of items, enabling the diffusion process to gradually recover a coherent set of stroke segments while jointly modeling their positions, sizes, and shapes. Experiments on the QuickDraw dataset showed that the proposed approach outperformed Sketch-rnn and SketchKnitter in terms of Frechet Inception Distance (FID),

收稿日期: 2025-07-16; 定稿日期: 2025-10-02; 通信作者: 徐鹏飞, E-mail: xupengfei.cg@gmail.com

Received: 16 July, 2025; Finalized: 2 October, 2025; Corresponding author: XU Pengfei, E-mail: xupengfei.cg@gmail.com

基金项目: 国家自然科学基金(62472287); 深圳市自然科学基金(JCYJ20250604181519025)

Foundation items: National Natural Science Foundation of China (62472287); Natural Science Foundation of Shenzhen City (JCYJ20250604181519025)

Precision, and Recall. In tasks with fewer strokes, the model captured local geometric details more effectively and achieved higher recall, while in tasks with more strokes, it demonstrated greater structural accuracy and fidelity. Qualitative comparisons further indicated that the generated sketches exhibited stronger structural coherence, richer details, and better spatial consistency. These results confirmed that the adoption of a layout-based perspective, combined with distance field representation and discretization, effectively reduced error accumulation in sequential modeling and improves both structural integrity and diversity in sketch generation. The framework also provided directions for enhancing stroke segmentation, detail recovery, and inter-segment connectivity in more complex scenarios.

Keywords: vector sketch; layout generation; stroke decomposition; stroke representation and learning; distance field; diffusion model

草图作为人类视觉认知与创意表达的重要载体,在概念设计、数字艺术创作和人机交互等领域具有不可替代的作用。现有基于深度学习的草图生成方法普遍采用折线(Polyline)或贝塞尔曲线(Bézier curve)作为基本表示单元,这类显式表示方式在几何表征层面存在本质性局限。具体而言,折线需要极高细分密度才能准确逼近曲线特征,导致数据冗余和计算负担;贝塞尔曲线虽然具有参数化优势,但其固定阶数的特性难以同时适应平滑弧线 with 尖锐折角的多样化表达需求,在表征复杂几何特征时面临保真度与效率的双重困境。

另一个问题是,现有方法大多预测完整的笔画运动及抬起情况。其逐点的运动预测虽然能产生流畅的轨迹,但会产生累计误差,导致最终生成的草图出现明显的变形。笔画某一时刻的位置需要通过累加之前所有时刻的运动来计算,且累计机制在笔画需要大范围移动时尤其易出现预测失准,从而导致一些重要的局部细节未能绘制到正确的位置,如车窗被绘制到车身之外。

为了解决上述几何表征和累计误差的2个核心问题,本研究将草图生成视为一种布局建模任务。将完整草图拆解为若干个相互独立的最小绘制单元(称为笔画段),通过一个基于离散扩散的去噪网络^[1],联合建模这些笔画段的位置、尺寸与类型。在生成过程中,模型从全掩码初始化出发,逐步采样出结构合理的笔画段集合。去噪过程中,各笔画段的信息彼此协调、互为约束,从而使生成结果在空间结构上更加一致,有效捕捉草图中的层次与构型特征。

为了为笔画段形态提供高质量的几何表达基础,本文提出使用笔画段距离场(Primitive Distance Field, PDF)作为表示手段。该方法借鉴了三维形状生成中无符号距离函数(Uncolored Distance Function,

UDF)^[2]的思想,将每一笔画段在二维画布中表示为一个连续的标量场,记录画布上任意一点到该笔画段的最短距离。该表示方式对笔画的具体形状没有任何限制,天然支持曲线、折角等多样形态,具备良好的可微性和表达灵活性。

在此基础上,本文引入编码词典(Codebook)机制^[3]以实现笔画段形态的离散化建模。考虑到草图中常见的结构具有高度重复性,编码词典能够在训练过程中自动识别并归纳形态相似的笔画段,将其归类为有限个离散词项。将连续的笔画形态转化为离散序列后,可以引入离散去噪(或掩码预测)机制来学习笔画间的结构关系。最终,模型能够在联合建模的过程中,从掩码中逐步恢复出具有丰富结构信息的笔画段集合,构成完整的草图布局。

从定量评估和定性分析的实验结果来看,本文提出的方法在草图结构的完整性、细节表现的丰富程度方面均显著优于现有主流方法,充分展示了PDF在草图生成任务中强大的潜力与广阔的应用前景。

1 相关工作

1.1 草图生成

早期的草图生成任务通常被视为一种图像风格转换问题^[4-6]。一些研究尝试通过对图像边缘图进行后处理来生成近似草图^[7-8];另一些方法则借助生成对抗网络,发展出涂鸦草图生成^[9-10]、图像引导草图生成^[11]、彩色草图生成^[12]以及带有铅笔阴影效果的艺术素描生成方法^[13]。然而,这些方法均依赖像素级图像生成,缺乏对笔画结构和绘制路径的建模能力,因而在结构表达与手绘风格的保真度上存在不足。

为解决上述问题,部分研究开始关注矢量草图的生成。典型方法包括基于离散点序列^[14-15]、SVG

命令^[16-17]和贝塞尔曲线^[18]的序列建模,以通过学习草图的绘制顺序来建模笔画。然而,由于受自回归序列模型在处理长距离依赖时的局限性限制,在生成结构复杂、笔画细节丰富的草图方面往往表现不佳。

近期的研究逐渐摆脱了对自回归生成机制的依赖。例如, SketchKnitter^[19]与 Chirodiff^[20]分别引入扩散模型对笔画点序列进行建模,显著提升了生成质量与稳定性; SketchINR^[21]则使用隐式神经表示,从笔画编号和时间索引中预测笔坐标位置。这些方法虽然在结构完整性方面取得一定进展,但仍以序列为基本建模单位,模型更关注笔画之间的先后关系,而非草图整体的空间布局 and 结构关系。本文提出的方法以无序的笔画段为基本建模单元,摆脱了点级序列建模的限制。

1.2 布局生成

布局生成任务的核心在于对离散元素的空间分布与语义关系进行建模,同时保持整体结构的一致性。早期的研究主要采用自回归序列生成的方法,如 LayoutTransformer^[22]通过 Transformer^[23]解编码器以固定顺序逐元素生成布局。虽然其能够捕捉局部依赖关系,但严格的生成顺序限制了布局的多样性,且难以有效建模元素间的长程依赖。

为了突破自回归框架的局限性,研究者转向了掩码填充式的生成范式。BLT^[24]借鉴了掩码语言建模的思想,将布局生成转化为“填空”任务,利用双向 Transformer 编码器推断缺失元素的位置和类别。该方法提升了全局一致性的建模能力,但仍需预设固定的元素数量,限制了其在动态场景下的适用性。

近年来,扩散模型^[25]为布局生成提供了新的思路。连续空间的扩散方法通过逐步去噪优化布局,但直接处理连续坐标可能导致结构稳定性不足。为此, D3PM^[1]提出了离散扩散框架,在离散值域内定义状态转移矩阵,使生成过程更具可控性。与此同时, 编码词典^[3]机制的引入进一步推动了离散扩散的发展。VQDiffusion^[26]利用特征离散化将图像生成转化为符号预测任务,其 Mask-and-Replace 策略在保证生成质量的同时提升了计算效率。在此基础上, LayoutDM^[27]进一步提出了模态感知的离散扩散方法,针对位置、类别等不同模态设计独立的值域空间和转移规则,从而更好地协调跨模态的结构关系。

上述研究为本研究提供了重要启示:离散扩散

框架能够有效维持结构一致性,而编码词典机制则有助于解决连续-离散表征的转换问题。通过将草图分解为离散化的笔画段集合,并采用模态感知的扩散生成策略,本方法能够更自然地捕捉草图布局的层次化特征和空间关系。

2 笔画特征学习

现有的草图数据集大多以折线段形式记录每个笔画,这种低级几何表示虽然对渲染友好,但在结构化特征建模方面存在明显劣势。手绘草图中的笔画常常具有高度的随意性,可能包含自交、锯齿等高频细节,且复杂笔画的形态差异显著、出现频次难以预测,使得以笔画为单位的特征学习难以提取稳定、通用的表示。为了获得高质量的笔画段特征表示并构建词典,本文提出了一种基于绘制过程的结构化切分策略:将每条笔画按点序划分为多个小段,每一小段即构成一个候选笔画段。接着,再利用自编码器对这些笔画段进行重建训练,提取其在潜在空间中的几何表征。

本文仍将这种表示称为“矢量”,目的是强调其相对于像素栅格而言是一种连续的表征方式。下面将详细介绍笔画段切分、笔画自编码器,笔画编码字典设计与训练细节。

2.1 笔画段切分

本文基于绘图的点序列提出了一种自适应的笔画段分解算法,用以将复杂笔画划分为结构清晰的基本笔画段。该算法通过追踪笔画绘制过程中的角度变化,判断是否在某个点进行切分。如图 1 所示,不同颜色表示划分出的不同笔画段,展示了复杂笔画在细粒度层面上的结构。



图 1 笔画段切分示例,不同笔画段以不同颜色标记
Fig. 1 Stroke segment decomposition example, where different segments are marked in different colors

本文的拆分策略如算法 1 所示。具体而言,算法依次计算当前点与相邻前后点所形成的夹角,并累计旋转角度。在当前旋转角度或累计角度超过设定阈值,或出现相邻转角方向相反且幅度显著的情形时,可将当前点作为新的分割点,从而完成笔画

段切分。该策略能够捕捉曲线变化剧烈或方向突变的局部特征, 使笔画划分更加结构化和可学习。

算法 1. 基于绘制过程的笔画分解。

输入: 点序列 $s = p_1, p_2, \dots, p_{N_p}$, 其中 $N_p \geq 3$ 。

输出: 分解后的笔画段序列。

步骤 1. 初始化变量: $i \leftarrow 0, j \leftarrow 1, a_c \leftarrow 0$;

步骤 2. 进入主循环, 当 $j < N_p - 1$ 时, 执行以下步骤:

步骤 2.1. 计算向量差值: $v_1 = p_j - p_{j-1}$,

$v_2 = p_{j+1} - p_j$;

步骤 2.2. 计算当前旋转角度: $a \leftarrow \text{signed_angle}(v_1, v_2)$;

步骤 2.3. 判断是否需要分解: 若 $\text{need_decompose}(a, a_c)$ 为真, 则

执行切分操作 $\text{split}(s, i, j)$

累计角度清零: $a_c \leftarrow 0$

更新起始点: $i \leftarrow j + 1$

步骤 2.4. 否则, 更新累计旋转角度:

$a_c \leftarrow a_c + a$;

步骤 2.5. 移动滑窗指针: $j \leftarrow j + 1$ 。

基于角度的判定符合人类绘制草图的习惯: 实际书写过程中, 断笔往往出现在笔画转折处。因此, 即便生成的草图在笔画间未能做到完全连续衔接, 其断开位置通常也显得合理。但需要说明的是, 该策略并非面向对笔画连续性要求极高的场景(如文字书写), 在此类任务中可能并不适用。

在实现中, 分解条件由 3 个阈值控制: 当单步转角超过 136° 、累计旋转角超过 181° , 或相邻转角方向相反且合并幅度超过 20° 时触发切分。通过这些约束, 算法既能避免局部尖锐折角和整体掉头, 又能抑制短距离的来回折返, 从而得到更规则、更便于建模的笔画段表示。

2.2 笔画自编码器

为了更好地学习笔画的几何结构特征, 本文提出了一种基于 PDF 的笔画自编码器。该方法通过对各个笔画段进行空间几何建模, 从而获得结构化的特征表示, 增强网络对笔画形状的理解能力。图 2 展示了本文的笔画自编码器结构。




图 2 本文的笔画自编码器结构

Fig. 2 Structure of the stroke autoencoder proposed in this paper

在网络输入阶段, 首先对归一化后的笔画段 $s = \{p_1, p_2, \dots, p_{N_p}\}$ 进行均匀采样, 得到一组具有等间距分布的笔画点。同时, 在画布上均匀采样 N_q 个查询点 $\{q_i\}_{i=1}^{N_q}$, 并计算这些点到笔画的欧几里得距离, 得到真实的距离场 $d = \{d_i\}_{i=1}^{N_q}$, 作为后续训练的监督信号。这些预处理数据构成了自编码器的输入。

与以往直接建模笔画点序列的方法不同, PDF 能够强调笔画区域的重要性, 增强网络对几何轮廓

的感知能力。在笔画形状存在较强不确定性、细节变化频繁的情况下, 该方法仍能稳定地学习到笔画的整体结构, 从而提升编码器的鲁棒性与泛化能力。

随后, 本文将笔画段上均匀采样的点位置进行位置编码后, 输入到自注意力模块中进行特征提取, 得到每个点的隐向量表示 $\{f_i\}_{i=1}^{N_p}$ 。将其特征进一步送入 2 个线性投影层生成均值向量 μ_i 和方差参数 $\log \sigma_i^2$ 。

通过重参数化技巧得到正则化后的表示为

$$\mathbf{z}_i = \boldsymbol{\mu}_i + \boldsymbol{\sigma}_i \cdot \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim N(0,1) \quad (1)$$

最终获得正则化后的笔画特征集合 $\{\mathbf{z}_i\}_{i=1}^{N_p}$ 。这些隐向量将在下一章被用于构建编码词典，提取来自真实草图中的笔画共性特征。

本文采用 Transformer 的交叉注意力机制将笔画特征映射至距离场空间。查询点特征作为 Query，笔画点特征作为 Key 和 Value，计算注意力权重后对笔画特征进行加权插值，从而预测每个查询点对应的距离值 $\hat{d} = \{\hat{d}_i\}_{i=1}^{N_q}$ 。

整个笔画编码器的训练目标由重建损失(预测距离值与真实距离值之间的差异)和 KL 正则化损失(鼓励编码特征满足结构化高斯分布)，即

$$L_{\text{rec}} = E_{\mathbf{x} \in \mathbb{R}^2} [\|\mathbf{d} - \hat{\mathbf{d}}\|_1] \quad (2)$$

$$L_{\text{KL}} = \frac{1}{N_p C'} \sum_{i=1}^{N_p} \sum_{j=1}^{C'} \frac{1}{2} (\boldsymbol{\mu}_{ij}^2 + \boldsymbol{\sigma}_{ij}^2 - \log \boldsymbol{\sigma}_{ij}^2) \quad (3)$$

2.3 笔画编码词典

为了进一步提升笔画特征的表达能力与结构一致性，对笔画特征进行离散化编码，本节引入编码词典机制，如图 2 所示。该机制不仅提升了笔画特征的可重用性，也为后续基于离散状态空间的草图生成打下基础。

这种机制来源于 VQ-VAE^[3]，是一种基于输入特征向量量化的网络架构，通过将输入向量映射为最邻近的码字，从而将连续空间离散为有限的词典集合。在本场景中，编码词典中的每一个码字可理解为一类常见的笔画样式，如顺滑的曲线、尖锐的折线，或具有某种规律性的笔划组合。通过对笔画特征进行量化，系统能在潜在空间中形成更加清晰的结构划分，为后续生成任务提供离散化、可控制的建模基础。

为了构建笔画编码词典，本文首先基于第 2.1 节提到的笔画段分解方法，将复杂笔画拆解为更具几何共性的基本笔画段。接着，使用第 2.2 节中介绍的笔画自编码器对每个笔画段进行编码，得到其对应的特征向量集合 $\{\mathbf{z}_i\}_{i=1}^{N_p}$ 经过一维卷积与展平操作，形成待量化的向量

$$\mathbf{z}_q = \text{Flatten}(\text{Conv 1D}(\{\mathbf{z}_i\}_{i=1}^{N_p})) \in \mathbb{R}^{N_p \cdot C'} \quad (4)$$

式中：Conv 1D(·) 表示一维卷积；Flatten(·) 表示将特征序列拼接为一维向量，作为量化模块的输入。矢量量化通过查找输入特征与编码词典中最接近的码字，实现特征的离散表示。假设码字集合为

$$\mathbf{C} = \{\mathbf{c}_1, \mathbf{c}_2, \dots, \mathbf{c}_K\} \subset \mathbb{R}^n$$

每个码字 $\mathbf{c}_K$ 是一个原型向量，量化操作定义为

$$\mathbf{Q}(\mathbf{z}) = \text{Argmin}_{\mathbf{c}_K \in \mathbf{C}} \text{dist}(\mathbf{z}, \mathbf{c}_K) \quad (5)$$

即从编码词典中选择距离最近的编码作为量化结果。其中 dist(·, ·) 表示距离度量函数，常见选择包括欧几里得距离与余弦相似度。

为使码字更新更加平滑，缓解训练过程中可能出现的“码本坍塌”现象，本文引入指数移动平均(Exponential Moving Average, EMA)机制，对码字进行更新，即

$$\mathbf{c}_K^{\text{new}} = \beta_{\text{decay}} \cdot \mathbf{c}_K^{\text{old}} + (1 - \beta_{\text{decay}}) \cdot \mathbf{z} \quad (6)$$

式中： $\beta_{\text{decay}} \in [0,1]$ 表示控制历史信息的保留比例。该策略可以在不依赖小批量波动的前提下，稳定调整词典结构。

此外，为了鼓励编码器输出的特征贴近词典中已有码字，减少潜在空间漂移，本文引入承诺损失(Commitment loss)，即

$$L_{\text{commit}} = \beta_{\text{commit}} \cdot \|\mathbf{z} - \text{sg}(\mathbf{c}_K)\|_2^2 \quad (7)$$

式中：sg(·) 表示停止梯度操作； β_{commit} 表示控制对齐强度。该项损失有助于提升隐空间的紧凑性与可控性。

最终，笔画编码模块的训练损失函数为

$$L = L_{\text{rec}} + \lambda_{\text{KL}} \cdot L_{\text{KL}} + L_{\text{commit}} \quad (8)$$

式中： λ_{KL} 表示 KL 正则化权重； L_{KL} 与 L_{rec} 分别表示第 2.2 节定义的重建损失与 KL 正则化损失。

3 草图布局生成

基于第 2 节所提出的笔画段表示和笔画编码方法，本节构建一个基于离散状态空间的草图布局生成模型。在进入具体生成策略之前，首先介绍离散型扩散模型(Discrete diffusion model)的基本思想与核心公式。

3.1 离散型扩散模型

扩散模型^[25]作为生成模型，其基本原理是对一组训练数据逐步添加噪声构造扩散过程，再通过学习逆过程还原原始样本。离散型扩散模型^[1]将该过程定义在有限状态集合上，适用于符号化、离散化的结构生成任务，如文本、图像中的离散标记或本工作中的笔画段序列。

设扩散过程在 T 个时间步上进行，对于任一时间步 t ，类别变量 $\mathbf{z}_t$ 的状态通过一个离散转移矩阵 $\mathbf{Q}_t \in [0,1]^{K \times K}$ 来描述，表示从上一状态 $\mathbf{z}_{t-1}$ 转移到 $\mathbf{z}_t$

的概率, 即

$$q(\mathbf{z}_t | \mathbf{z}_{t-1}) = \mathbf{v}(\mathbf{z}_t)^T \mathbf{Q}_t \mathbf{v}(\mathbf{z}_{t-1}) \quad (9)$$

式中: $\mathbf{v}(\mathbf{z})$ 表示离散变量 $\mathbf{z}$ 的 one-hot 编码。

扩散过程满足马尔可夫性, 因此给定初始状态 $\mathbf{z}_0$ 后, 类别变量在第 t 个时间步的状态分布可由转移矩阵序列递推得到

$$q(\mathbf{z}_t | \mathbf{z}_0) = \mathbf{v}(\mathbf{z}_t)^T \mathbf{Q}_t \mathbf{Q}_{t-1} \cdots \mathbf{Q}_1 \mathbf{v}(\mathbf{z}_0) \quad (10)$$

在训练中, 利用该前向过程引入噪声样本, 同时训练一个神经网络 $p_\theta(\mathbf{z}_{t-1} | \mathbf{z}_t)$ 来近似逆扩散过程, 从而实现从随机噪声中逐步采样生成结果。

基于离散扩散模型的思想, 本文设计了离散草图生成扩散模型, 用于确定每个笔画段的位置、大小和类型, 并逐步构建符合笔画段结构约束的草图表示。

3.2 基于笔画编码词典的草图生成扩散模型

如第 2.1 节所述, 本文将草图表示为由多个笔画段组成的集合, 每个笔画段由五元组表示: 类别标签 k^i 、左上与右下坐标 $(x_{\min}^i, x_{\max}^i, y_{\min}^i, y_{\max}^i)$, 其中 $i=1, 2, \dots, N$ 表示笔画段索引。

类别标签 k^i 来源于笔画段编码词典中的离散化结果; 而坐标 $(x_{\min}^i, x_{\max}^i, y_{\min}^i, y_{\max}^i)$ 由笔画段的包围盒决定。为了构建更具结构性的离散表示, 本文对坐标值进行归一化, 并采用 KMeans 聚类算法对每个坐标项分别离散化, 以使得坐标的离散分布更均衡。整幅草图可表示为

$$\mathbf{s} = \{\mathbf{c}_i\}_{i=1}^N \quad (11)$$

$$\mathbf{c}_i = (k^i, x_{\min}^i, x_{\max}^i, y_{\min}^i, y_{\max}^i) \quad (12)$$

离散扩散模型通过一系列转移矩阵对笔画段进行逐步加噪。在每一个时间步 t , 笔画段的每个字段都有可能被替换为词典中的其他值, 或被替换为特殊符号 [MASK]。一旦某一字段被置为 [MASK], 其状态将被冻结, 不再发生变化, 直到扩散过程终止。

为了实现这一策略, 本文定义每个字段对应的转移矩阵 $\mathbf{Q}_t \in [0, 1]^{(K+1) \times (K+1)}$ 。其中 K 为字段可能的离散取值数量, 其中, $\mathbf{Q}_t$ 的最后一行和列对应 [MASK] 状态。具体来说:

矩阵 $\mathbf{Q}_t$ 的对角线元素取值为 $\alpha_t + \beta_t$, 表示保留当前值的概率;

矩阵 $\mathbf{Q}_t$ 的最后一列的所有元素(不含最后一个)取值为 γ_t , 表示从当前值转移为 [MASK] 的概率;

矩阵 $\mathbf{Q}_t$ 的非对角线、非 [MASK] 列的其余元素

取值为 β_t , 表示被均匀替换为其他非掩码值的概率。

随着时间步 t 增加, γ_t 逐渐增大, 最终所有状态都将被替换为 [MASK], 实现完全加噪。

模型采用 Transformer 结构建模逆扩散过程, 预测条件概率 $p_\theta(\mathbf{z}_{t-1} | \mathbf{z}_t, \mathbf{y})$ 。训练目标是近似马尔可夫后验分布 $q(\mathbf{z}_{t-1} | \mathbf{z}_t, \mathbf{z}_0)$, 从而最大化变分下界。由贝叶斯定理, 后验分布矩阵某一点的概率为

$$q(x_{t-1} = j | x_t = k, x_0 = i) = \frac{\mathbf{Q}_t[j, k] \cdot \mathbf{Q}_{t-1}[i, j]}{\mathbf{Q}_{t-1}[i, k]} \quad (13)$$

式中: 累计转移矩阵 $\mathbf{Q}_{1:t} = \mathbf{Q}_1, \mathbf{Q}_2, \dots, \mathbf{Q}_t$ 。

训练时本文以后验作为目标监督, 训练模型输出近似的条件概率 p_θ 。通过该建模方式, 模型可以有效模拟笔画段布局在时间上的退化与还原过程, 从而逐步生成结构清晰的草图。图 3 展示了离散扩散模型生成草图的去噪过程示意。模型首先以全 [MASK] 笔画段序列作为初始状态(即空白图), 随后在每个时间步逐步替换部分序列信息, 每次替换可能调整笔画段的位置, 及改变笔画段的类型, 也可能是保留当前状态, 直到整个草图完全生成。随着生成的推进, 结构逐渐丰满, 笔画段之间的空间关系也逐步明朗, 最终还原出完整清晰的草图结构。




图 3 本文离散扩散生成模型的生成过程演示, 其中虚线框代表笔画段的位置信息

Fig. 3 Demonstration of the generation process of the discrete diffusion model, where dashed boxes represent the position information of stroke segments

4 笔画渲染

由于本方法生成的笔画段是以距离场表示的, 而非直接回归笔画路径, 因此在推理阶段后, 本文设计了一套从距离场中提取原始笔画的算法。目标是将 PDF 转换为渲染的笔画路径。

直接使用 Marching Square 提取出的等值线可能存在多个闭合曲线或干扰曲线, 无法直接还原原始笔画。为了更高效地恢复原始笔画, 本文提出了一种基于局部极小值点检测与最近邻排序的简化方法, 以降低误差传播并提升重建稳定性。具体而言, 首先对每个笔画段生成的距离场进行遍历, 提取所有局部极小值点, 这些点在距离分布中最靠近

笔画的中心线。接着,将这些点视为二维点云,并通过基于起点启发的最近邻搜索算法对其进行排序,构建出一条连贯的笔画路径。之后进一步对排序后的路径应用滑动平均滤波操作,以得到连续平滑的笔画序列,最终实现高质量的笔画重建。

图 4 展示了该方法的实际效果。左图为 PDF 及其检测出的极小值点(红点),右图为基于点集构建出的最终笔画路径。




图 4 笔画渲染过程示意

Fig. 4 Illustration of the stroke rendering process

在本文实验中,UDF 图像的分辨率设定为 192,由此决定了极值点坐标的精度。此后所有处理均基于提取的点坐标进行,且不再依赖具体的分辨率。尽管从理论上讲,该过程相较于直接输出序列略显耗时,但在常见的硬件配置下,整体开销仅为毫秒量级,几乎可以忽略,不会带来感知上的差异。

5 实验与算法评估

5.1 数据集预处理

本文在 QuickDraw 数据集上训练和评估所提出的草图生成方法。QuickDraw 是一个大规模的手绘草图数据集,包含大约 5 000 万幅草图,涵盖 345 个类别,具有较高的多样性和结构复杂性。为了保证实验的可控性与计算效率,本文从中选取 10 个具有代表性的类别进行研究,分别为: Airplane, Apple, Bus, Fish, Lion, Moon, Shoe, Spider, Train 和 Umbrella。每个类别包含 70 000 个训练样本。

在获取原始笔画数据后,本文应用第 2.1 节中介绍的笔画段分解算法对每条笔画进行处理,将复杂笔画拆解为多个笔画段以适应特征学习与编码。在此基础上,为了更好地区分草图结构复杂度,还根据每个类别中测试样本的平均笔画数量,将数据集划分为少笔画组(平均笔画数 ≤ 5)与多笔画组(平均笔画数 > 5),以此分析模型在不同复杂度条件下的定量性能表现。

此外,数据预处理过程中还去除了笔画数超过 32 的草图样本,因这类样本通常包含大量高频细节和无关线条,不利于模型收敛并可能对学习过程产生干扰。对于笔画编码器的训练,为提升网络在笔画中心区域的重建质量,除了在整个画布上进行均匀采样外,还在每个笔画段的线条周围增加采样密度,以捕捉更多局部细节,从而学习更稳定、泛化能力更强的笔画段表示。

5.2 实现细节

在实现过程中,本文首先训练笔画编码器网络以获取高质量的笔画特征表示。在网络结构上,编码器采用 512 个通道数,KL 正则化后的特征维度为 64,输入的笔画段笔画由 16 个均匀采样点组成。为构建笔画距离场,将其渲染为 192×192 分辨率,笔画宽度为 1。编码词典的大小设为 256,并使用 AdamW 优化器进行训练,初始学习率为 0.000 1。训练中采用 $\beta_{\text{decay}}=0.8$ 和 $\beta_{\text{commit}}=1.0$ 的权重更新策略,在采样对靠近笔画区域的采样点设置损失权重 $\lambda_{\text{close}}=0.1$,以确保收敛稳定。KL 正则化损失的权重 λ_{kl} 设置为 0.001。在上述设置下,训练笔画编码器网络大约需要 30 h。

完成笔画编码后,进一步训练草图生成扩散模型。在训练前,本文对草图的原始笔画顺序打乱,并利用第 2.1 节中的笔画段分解算法对笔画进行处理。生成模型基于离散扩散机制,设置的去噪步数为 100,单幅草图中最多包含 32 条笔画。模型结构中设置编码器深度为 16,通道数为 512,注意力头数为 32,优化器同样采用 AdamW,初始学习率为 0.000 1,总训练轮数为 50,其训练草图生成模型约需 50 h。

5.3 基线方法

本文选取的对比方法分别基于自回归模型与扩散模型的 Sketch-rnn^[14]和 SketchKnitter^[19]模型,建模手绘草图的笔画偏移量及笔抬起事件,能够生成高质量、结构清晰的草图样本。本文在相同的数据集和预处理条件下复现了上述方法的实验,并使用一致的评估指标进行量化比较。

5.4 定量对比

为系统评估所提出方法的草图生成效果,本文采用 FID (Frechet Inception Distance)、精确率 (Precision)与召回率(Recall)共 3 类主流评估指标。

其中, FID 衡量生成图像与真实图像在 Inception-V3 特征空间中分布差异,数值越低代表

生成图越接近真实分布。其计算式为

$$FID = \|\mu_r - \mu_g\|^2 + \text{Tr}(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2}) \quad (14)$$

式中: μ_r 和 μ_g 分别表示真实图像与生成图像的均值向量; Σ_r 和 Σ_g 表示对应的协方差矩阵; Tr 表示矩阵的迹。

Precision 和 Recall 用于评估生成样本的质量与模式覆盖度。前者衡量生成样本是否落入真实样本分布的支持区域, 反映生成结果的保真性; 后者衡量生成模型是否能覆盖所有真实样本的模式, 体现生成结果对真实分布的完整性还原能力。计算式分别为

$$Precision = \frac{1}{N_g} \sum_{i=1}^{N_g} \mathbb{1}(\text{dist}(g_i, R) \leq \delta) \quad (15)$$

$$Recall = \frac{1}{N_r} \sum_{j=1}^{N_r} \mathbb{1}(\text{dist}(r_j, G) \leq \delta) \quad (16)$$

式中: N_g 和 N_r 分别表示生成样本与真实样本数量; g_i 和 r_j 分别表示生成图像和真实图像; R 和 G 分别表示真实图像集与生成图像集; δ 表示距离阈值; $\mathbb{1}$ 表示示性函数, 即条件为真时等于 1, 条件为假时等于 0。

表 1 和表 2 展示了本方法与对比方法在不同笔画复杂度下的定量对比结果。

表 1 少笔画(≤ 5)任务定量比较结果

Table 1 Quantitative comparison results for sketches with few strokes (≤ 5)

方法	FID↓	Precision↑	Recall↑
Sketch-rnn	31.607	0.489	0.449
SketchKnitter	26.183	0.537	0.464
本文	25.496	0.456	0.581

注: ↓表示数值越小越好; ↑表示数值越大越好; 加粗数据表示最优值。

表 2 多笔画(>5)任务定量比较结果

Table 2 Quantitative comparison results for sketches with many strokes (>5)

方法	FID↓	Precision↑	Recall↑
Sketch-rnn	35.307	0.482	0.432
SketchKnitter	33.984	0.551	0.410
本文	32.087	0.576	0.396

注: ↓表示数值越小越好; ↑表示数值越大越好; 加粗数据表示最优值。

在定量指标方面, 本文方法在少笔画(≤ 5)和多笔画(>5)任务中均取得了最优的 FID 分数, 表明其能够更有效地建模真实草图数据的分布, 生成结果在整体外观上更为逼真。

特别是在 Precision 指标上, 本文方法在多笔画任务中优于其他方法。这得益于笔画段级的表示方式规避了传统笔画顺序建模中误差累积的问题: 本文仅对每个笔画段的绝对位置和大小建模, 而非依赖于连续笔画的位移预测, 从而提高了结构精度。

而在少笔画任务中, 由于笔画段切分机制将长笔画拆解为更小的单元, 使模型能够更充分学习局部几何形状, 从而在 Recall 指标上表现更优。由于笔画段切分机制将原本连贯的长笔画拆分为更小的单元, 导致生成时难以保持笔画的连续性, Precision 指标略有下降。

尽管在部分指标上本文方法略低于对比方法, 但整体上本文方法在保持生成质量和样式多样性方面达到了更好的平衡。

5.5 定性对比

为进一步验证本文方法在草图生成任务中的有效性, 对比了 Sketch-rnn^[14]、SketchKnitter^[19]和本方法在 10 个类别上的生成效果, 结果如图 5 所示。




图 5 矢量草图生成结果定性对比

Fig. 5 Qualitative comparison of vector sketch generation results

从图 5 中可以观察到, Sketch-rnn 虽然在部分样例中能够生成具有辨识度的草图,但整体结构往往较为松散,存在笔画断裂、比例失衡等问题。SketchKnitter 在结构完整性和类别识别性上表现更优,但仍存在笔画偏移、局部重复或缺失等现象,尤其在细节复杂的类别中较为明显。

相比之下,本文方法生成的草图在整体结构一致性、局部细节还原和笔画分布协调性上均表现更佳。如在 Apple 和 Spider 类别中,生成图清晰表达出笔画段之间的位置关系和形状边界;在 Bus 和 Train 等结构复杂的类别中,生成图保留了良好的空间布局与细节层次,显示出较强的建模能力。

5.6 消融实验

为了评估编码词典大小对生成质量的影响,本文在保持其他设置不变的条件下,分别测试了词典大小为 64, 128, 256 和 384 时模型的表现。实验结果见表 3。

表 3 词典大小对生成质量的影响

Table 3 Influence of codebook size on generation quality

词典大小	FID↓	Precision↑	Recall↑
64	44.681	0.351	0.412
128	36.018	0.401	0.477
256	25.496	0.456	0.581
384	35.174	0.413	0.482

注: ↓表示数值越小越好; ↑表示数值越大越好; 加粗数据表示最优值。

结果表明,过小的词典容量会限制模型对笔画类型和细节的表达能力,导致生成笔画段之间的语义差异不足、结构不清晰。而词典容量过大虽然提升了表示能力,但也容易出现“dead code”现象,即部分编码项在训练中几乎从未被激活。这不仅增加了训练负担,还可能降低生成稳定性。图 6 展示了在 256 的词典大小设置下,原始草图与编码词典还




图 6 编码词典笔画重建结果((a),(c) 原始草图; (b),(d) 重建结果)

Fig. 6 Stroke reconstruction results using the codebook ((a),(c) Original sketch; (b),(d) Reconstructed result)

原后的草图样本对比,表明此大小的编码词典可以在保持结构一致性的同时有效保留笔画段细节。综合 FID、精确率与召回率指标,词典大小设置为 256 时表现最优,达成表达能力与训练效率的良好平衡。

6 结束语

本文提出了一种基于布局建模的草图生成方法,通过 PDF 与编码词典相结合,实现了对草图结构的高质量建模与离散生成。该方法不仅有效缓解了传统笔画序列建模中累计误差带来的变形问题,同时在结构完整性与细节表现方面取得了显著提升。本文从三维形状生成中借鉴无符号距离函数的思想,构建了灵活可微的笔画段表示方式,并结合词典化编码机制,促使模型能够从复杂形态中自动归纳出高频的几何结构,实现对笔画段形态的离散化建模与高效重构。

尽管实验结果验证了该方法的有效性,但仍存在若干值得进一步研究的问题。首先,当前采用的笔画段分解策略基于启发式规则,在面对复杂或连笔较强的草图时,可能会引入不必要的过度分割,影响结构表达的紧凑性。其次,由编码词典重建的笔画段通常表现出较强的平滑性,尽管有利于建模,但也可能导致部分局部细节的丢失。最后,由于各笔画段在生成过程中是以块状单元独立建模的,模型尚未显式对段与段之间的连接性进行约束,因此在某些结果中仍可能出现段与段之间的微小空隙或错位。

本方法在结构建模与生成质量方面展现出较强潜力,但仍有进一步提升的空间。未来工作可围绕笔画段分割策略、细节还原能力以及段间连接一致性展开,以推动该布局生成框架在更复杂草图场景中的实用性与稳健性。

参考文献 (References)

- [1] AUSTIN J, JOHNSON D D, HO J, et al. Structured denoising diffusion models in discrete state-spaces[C]//The 35th International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2021: 1376.
- [2] LONG X X, LIN C, LIU L J, et al. NeuralUDF: learning unsigned distance fields for multi-view reconstruction of surfaces with arbitrary topologies[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition. New York: IEEE Press, 2023: 20834-20843.
- [3] VAN DEN OORD A, VINYALS O, KAVUKCUOGLU K. Neural discrete representation learning[C]//The 31st

- International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2017: 6309-6318.
- [4] 郑屹, 黄向, 秦菲儿, 等. 2D/3D 生成式人工智能技术发展及创意产业应用[J]. 中国图象图形学报, 2025, 30(6): 1953-1984.
 - ZHENG Y, HUANG X, QIN F E, et al. AIGC 2D/3D technology development and creative industry applications[J]. Journal of Image and Graphics, 2025, 30(6): 1953-1984 (in Chinese).
 - [5] 刘安安, 苏育挺, 王岚君, 等. AIGC 视觉内容生成与溯源研究进展[J]. 中国图象图形学报, 2024, 29(6): 1535-1554.
 - LIU A A, SU Y T, WANG L J, et al. Review on the progress of the AIGC visual content generation and traceability[J]. Journal of Image and Graphics, 2024, 29(6): 1535-1554 (in Chinese).
 - [6] 李纪远, 管哲予, 宋海川, 等. 人在环路的细分行业 logo 生成方法[J]. 图学学报, 2025, 46(2): 382-392.
 - LI J Y, GUAN Z Y, SONG H C, et al. Human-in-the-loop field-specific logo generation method[J]. Journal of Graphics, 2025, 46(2): 382-392 (in Chinese).
 - [7] GUO C E, ZHU S C, WU Y N. Primal sketch: integrating structure and texture[J]. Computer Vision and Image Understanding, 2007, 106(1): 5-19.
 - [8] LI M T, LIN Z, MECH R, et al. Photo-sketching: inferring contour drawings from images[C]//2019 IEEE Winter Conference on Applications of Computer Vision. New York: IEEE Press, 2019: 1403-1412.
 - [9] GE S W, GOSWAMI V, ZITNICK L, et al. Creative sketch generation[EB/OL]. [2025-07-11]. <https://openreview.net/forum?id=gwnoVHIES05>.
 - [10] 赵鹏, 高杰超, 周彪, 等. 基于对抗自编码器的矢量草图生成方法[J]. 计算机辅助设计与图形学学报, 2020, 32(12): 1957-1966.
 - ZHAO P, GAO J C, ZHOU B, et al. A novel vector sketch generation method based on adversarial autoencoder[J]. Journal of Computer-Aided Design & Computer Graphics, 2020, 32(12): 1957-1966 (in Chinese).
 - [11] LIU R T, YU Q, YU S X. Unsupervised sketch to photo synthesis[C]//The 16th European Conference on Computer Vision. Cham: Springer, 2020: 36-52.
 - [12] MANUSHREE V, SAXENA S, CHOWDHURY P, et al. XCI-Sketch: extraction of color information from images for generation of colored outlines and sketches[EB/OL]. [2025-07-11]. <https://arxiv.org/abs/2108.11554>.
 - [13] LI S C, LI K, KACHER I, et al. ArtPDGAN: creating artistic pencil drawing with key map using generative adversarial networks[C]//The 20th International Conference on Computational Science. Cham: Springer, 2020: 285-298.
 - [14] HA D, ECK D. A neural representation of sketch drawings[EB/OL]. [2025-07-11]. <https://openreview.net/forum?id=Hy6GHpkCW>.
 - [15] RIBEIRO L S F, BUI T, COLLOMOSSE J, et al. Sketchformer: transformer-based representation for sketched structure[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition. New York: IEEE Press, 2020: 14141-14150.
 - [16] CARLIER A, DANELLJAN M, ALAHI A, et al. DeepSVG: a hierarchical generative network for vector graphics animation[C]//The 34th International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2020: 1372.
 - [17] LOPES R G, HA D, ECK D, et al. A learned representation for scalable vector graphics[C]//IEEE/CVF International Conference on Computer Vision. New York: IEEE Press, 2019: 7929-7938.
 - [18] DAS A, YANG Y X, HOSPEDALES T, et al. BézierSketch: a generative model for scalable vector sketches[C]//The 16th European Conference on Computer Vision. Cham: Springer, 2020: 632-647.
 - [19] WANG Q, DENG H G, QI Y G, et al. SketchKnitter: vectorized sketch generation with diffusion models[EB/OL]. [2025-05-16]. <https://openreview.net/forum?id=4eJ43EN2g6l>.
 - [20] DAS A, YANG Y X, HOSPEDALES T, et al. ChiroDiff: modelling chirographic data with diffusion models[EB/OL]. [2025-05-16]. <https://openreview.net/forum?id=1ROAstc9jv>.
 - [21] BANDYOPADHYAY H, BHUNIA A K, CHOWDHURY P N, et al. SketchINR: a first look into sketches as implicit neural representations[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition. New York: IEEE Press, 2024: 12565-12574.
 - [22] GUPTA K, LAZAROW J, ACHILLE A, et al. LayoutTransformer: layout generation and completion with self-attention[C]//IEEE/CVF International Conference on Computer Vision. New York: IEEE Press, 2021: 984-994.
 - [23] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//The 31st International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2017: 6000-6010.
 - [24] KONG X, JIANG L, CHANG H W, et al. BLT: bidirectional layout transformer for controllable layout generation[C]//The 17th European Conference on Computer Vision. Cham: Springer, 2022: 474-490.
 - [25] HO J, JAIN A, ABBEEL P. Denoising diffusion probabilistic models[C]//The 34th International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2020: 574.
 - [26] GU S Y, CHEN D, BAO J M, et al. Vector quantized diffusion model for text-to-image synthesis[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition. New York: IEEE Press, 2022: 10686-10696.
 - [27] INOUE N, KIKUCHI K, SIMO-SERRA E, et al. LayoutDM: discrete diffusion model for controllable layout generation[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition. New York: IEEE Press, 2023: 10167-10176.